DQN y A3C para invertir en un activo: cuatro mercados simulados y datos reales

[Autores] · Taller 2 de Aprendizaje por Refuerzo · noviembre de 2026

Resumen. Entrenamos DQN y A3C, además de Doble DQN, DQN en duelo y REINFORCE, en el entorno del enunciado sin modificarlo. Los comparamos con el agente aleatorio, *buy & hold* (B&H) y dos reglas fijas en las **mismas 100 series de test del taller anterior**, lo que permite comparar también con sus agentes tabulares. Todos aprenden la estrategia esperada en cada mercado. En ciclo empatan entre sí y con el tabular; en reversión, los métodos de actor (A3C, REINFORCE) superan a DQN y al tabular. Además, encontramos y corregimos un fallo de concurrencia que hacía parecer que A3C no convergía.

1. Diseño

- **Estado continuo, sin intervalos.** La red recibe (tendencia, posición) y generaliza entre tendencias parecidas. La tendencia se divide por su desviación típica, porque vale $\pm 0{,}3$ en ciclo y $\pm 0{,}05$ en el resto. La recompensa también se normaliza, en vez de recortarla a ± 1 como proponen las transparencias: recortar borraría la diferencia entre retornos pequeños y grandes.
- **DQN:** red 64×64, buffer de 10^5 transiciones, minibatch de 64 cada 4 pasos y red objetivo copiada cada 1.000 pasos. **A3C:** 4 procesos asíncronos con Adam compartido, actor y crítico separados ($\alpha_w = 3\alpha_\theta$) y entropía β como exploración. Omitimos el factor $I = \gamma^t$: optimiza solo el estado inicial, que aquí no tiene nada de especial. **REINFORCE** es el caso de un solo trabajador que actualiza al final del episodio, sin crítico.
- **Datos y métricas.** Cada episodio usa una serie nueva de 500 pasos. Validación y test (100 series cada uno) usan semillas separadas. Medimos la mediana del retorno en test, la ganancia $G = \sum r$ y el cociente geométrico del capital frente a cada referencia, con IC bootstrap pareado. Los pesos son los del mejor control en validación.
- **Ajuste** por etapas, solo en validación (3 semillas × 100 series): (A) $\alpha \times \gamma$; (B) exploración: en DQN, ε decae de 1 a 0,01 o 0,1 en el 30 % o el 70 % de los episodios (gana el 70 % en todos los mercados), y en A3C, β_0 y n pasos; (C) pérdida MSE o MAE; (D) episodios. La evaluación final usa 10 semillas nuevas.

	DQN					A3C (crítico con MAE)					REINFORCE			
Mercado	α	γ	ε_f	pérdida	ep.	α_θ	γ	β_0	n	ep.	α	γ	β_0	ep.
Ciclo	2e-3	0	0,01	MAE	400	3e-4	0	0,01	20	1.600	1e-3	0,5	0,01	800
Browniano	5e-4	0,99	0,01	MSE	400	3e-4	0,99	0,01	20	800	1e-3	0,99	0,01	800
Reversión	2e-3	0,5	0,01	MSE	400	3e-4	0,9	0,2	20	3.200	1e-3	0,9	0,05	1.600
Regímenes	5e-4	0,5	0,1	MSE	400	1e-4	0	0,01	5	800	3e-4	0,5	0,01	800

Por qué. En ciclo, $\gamma = 0$, como en el tabular: la inercia se ve en el paso siguiente. En reversión, γ alto, porque hay que aguantar la posición hasta que el precio vuelve a la media. En browniano y regímenes, casi todo acaba sin operar, y la variación entre configuraciones es del tamaño del error de 3 semillas (DQN en reversión: 2,3 frente a 2,1 puntos), así que esa elección es casi azar. A3C necesita más episodios que DQN, pero cada uno le cuesta 3 veces menos (41 frente a 131 ms).

2. Resultados en test

Agente	Ciclo	Browniano	Reversión	Regímenes	Convergencia en G, ciclo / reversión
Aleatorio	+456 (3,11)	−14,7	−15,2	−24,0	
Buy & hold	+3.425 (6,38)	+0,7	−1,1	−20,4	
Momentum	+48.189 (7,71)	−11,8	−28,7	−18,4	
Contrarian	−92,9	−14,3	+6,9	−22,6	
DQN	+59.363 (8,13)	0	+22,1 (0,25)	0	50 / 375 ep. ≈ 7 / 49 s
Doble DQN	+59.363 (8,13)	0	+21,0 (0,24)	0	50 / 350 ep. ≈ 7 / 47 s
DQN en duelo	+60.723 (8,18)	0	+22,2 (0,25)	0	50 / 375 ep. ≈ 8 / 61 s
A3C	**+63.619** (8,21)	0	**+27,5** (0,30)	0	50 / 3.200 ep. ≈ 2 / 130 s
REINFORCE	+59.905 (8,24)	0	+28,6 (0,30)	0	75 / 1.350 ep. ≈ 3 / 48 s
Taller ant.: Q-learning	+64.989	0	+22,0	+1,7	2.600 / 3.300 ep.† ≈ 24 / 30 s
Taller ant.: Sarsa	+67.861	0	+22,2	+4,7	600 / 3.700 ep.† ≈ 4 / 29 s
Oráculo (techo)	+1.193.433 (11,16)	+0,7 (0,09)	+77,3 (0,63)	+26,2 (0,26)	

Mediana del retorno (%) en test, con G media entre paréntesis; 100 series (× 10 semillas en los agentes entrenados).
†Criterio del taller anterior, sobre la mediana en %. Con ese mismo criterio: DQN, 400 / 375 episodios; A3C, 1.425 / 3.200.

- **Significación.** Todos los agentes superan a B&H y al aleatorio con IC del 95 % salvo en browniano, donde ninguno se distingue de B&H. En ciclo superan también a momentum, la mejor regla fija, por un factor de 1,25 a 1,35. Doble DQN coincide exactamente con DQN en ciclo: con $\gamma = 0$ el target es solo r y no hay `max` que sobreestimar, lo que sirve de comprobación.
- **¿Es la estrategia esperada?** Sí, según los mapas de la política sobre la tendencia continua:
  - **Ciclo:** *momentum* con histéresis. Compra por encima de $\approx +0{,}5\sigma$ y no vende hasta bajar de $\approx -0{,}7\sigma$, lo que ahorra comisiones.
  - **Reversión:** *contrarian* solo en los extremos. Compra por debajo de $\approx -1{,}5\sigma$ y mantiene hasta pasar de $+1$ a $+1{,}5\sigma$, que es donde el rebote compensa la comisión.
  - **Browniano:** no operar o B&H, equivalentes en un mercado sin señal.
  - **Regímenes:** no operar. La tendencia de 6 pasos no distingue los regímenes, y por eso el oráculo, que sí conoce el régimen, gana +26 %.
- **¿Tiene sentido?** Los agentes capturan el 74 % de la G del oráculo en ciclo y el 40–48 % en reversión: siempre por debajo del techo y por encima de la mejor regla fija (69 % y 18 %). La G en validación y en test casi coincide (A3C en reversión: 0,30 y 0,30), así que la elección del mejor control apenas infla el resultado.
- **Frente al tabular.** En rendimiento, empate en ciclo, mejora en reversión con los métodos de actor y pérdida del pequeño margen en regímenes: con una sola variable continua, 8–40 intervalos ya aproximaban bien la frontera. En convergencia, con el mismo criterio, DQN generaliza y en reversión necesita unas 10 veces menos episodios (375 frente a 3.300–3.700), pero cada uno cuesta 13 veces más y tarda algo más (49 frente a 29–30 s); A3C necesita tantos episodios como el tabular.

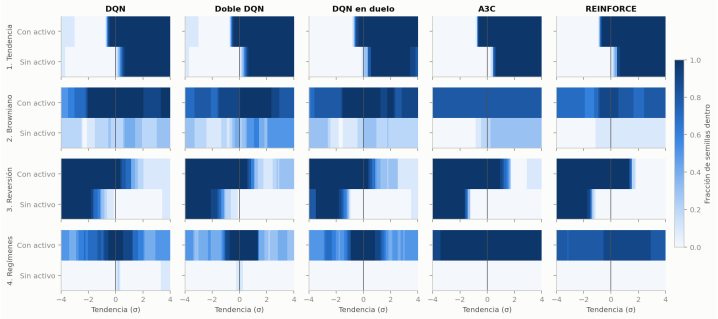


Figura 1: Política aprendida: fracción de las 10 semillas que quieren estar dentro del mercado, según la tendencia normalizada y la posición.

3. Convergencia de A3C

Un fallo que parecía falta de convergencia. Con la misma configuración y semilla, A3C a veces aprendía y a veces dejaba de operar para siempre. Lo destapó un test intermitente. Los procesos compartían el estado de Adam sin cerrojo: uno podía leer la media m recién escrita por otro con la varianza v aún a cero, y el paso $\alpha\, m/(\sqrt{v}+10^{-8})$ llevaba los pesos de 0,7 a más de 1.000 en una sola actualización. Con un cerrojo solo en ese paso, los gradientes se siguen calculando de forma asíncrona y los pesos se quedan en 0,71 en 30 de 30 pruebas. Al rehacer A3C:

- en reversión, la peor semilla pasa de +5,3 % a +25,2 % y la mediana, de +23,6 % a +27,5 %;
- los ajustes que no operaban bajan del 10 % al 4 %;
- el resultado ya no depende del número de trabajadores (1, 2, 4 y 8 tardan 57, 33, 23 y 21 s), aunque el cerrojo cuesta algo: sin él, 8 trabajadores tardaban 13–16 s.

Veredicto, con 12.800 episodios (4 veces el máximo del ajuste, 3 semillas):

- **Ciclo:** converge pronto y se mantiene (G entre 8,3 y 8,5, deriva 0,01, rango entre semillas 0,04).
- **Browniano:** salta entre B&H y no operar, que valen casi lo mismo.
- **Regímenes:** converge a no operar.
- **Reversión: no converge**. Cada semilla alterna entre $G \approx 0{,}12$ y $\approx 0{,}30$, y la oscilación no baja con más experiencia. DQN oscila incluso más: con los pesos del último control, en vez del mejor, DQN cae en test de +22,1 % a +2,6 % y A3C de +27,5 % a +15,9 %. Elegir el mejor control en validación es imprescindible en este mercado.

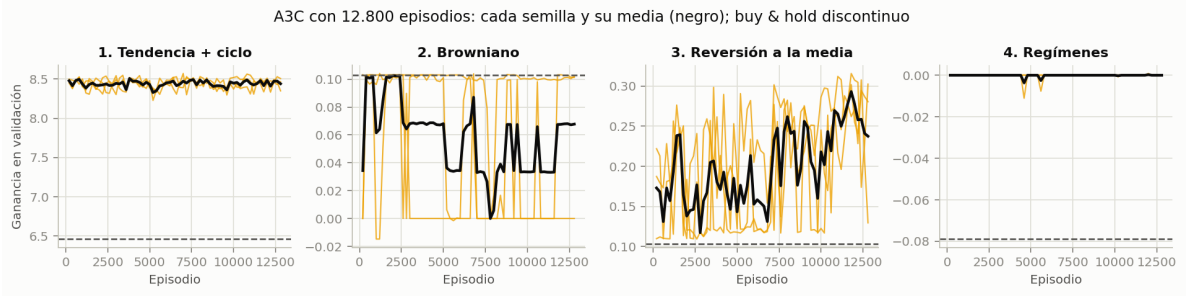


Figura 2: Prueba larga de A3C: ganancia G en validación.

4. Otras pruebas

- **MSE frente a MAE.** Ninguna diferencia supera el error de 3 semillas. En DQN, MSE es algo mejor en reversión (+28,3 % frente a +26,6 %) y con MAE deja de operar en browniano y regímenes. En el crítico de A3C es al revés (+26,6 % con MAE frente a +23,8 %). Lectura posible: la mediana del target ignora las colas que justifican entrar, mientras que un crítico que solo es línea base gana con la robustez de MAE.
- **Minibatch frente a episodio entero** (DQN, sin buffer). Una pasada por episodio iguala al minibatch: en reversión, +24,4 % frente a +22,1 %. Dieciséis pasadas, que suman tantas experiencias como el minibatch, hunden reversión a +10,8 %: la red se ajusta a las experiencias correlacionadas de la última serie. El valor del buffer aquí es no olvidar las series anteriores.
- **Datos reales** (entrenamiento hasta 2015, validación 2016–18, test desde 2019; configuración de regímenes, sin ajustar). Ningún agente supera a B&H, igual que en el taller anterior (allí, con otro periodo: S&P 500 +228 % frente a +232 %; IBEX +9 % frente a +117 %). Con una sola historia de test por activo, en años muy alcistas, no se puede generalizar.
  - A3C acaba haciendo B&H: S&P 500 +190 % frente a +193 %; IBEX +101 % frente a +111 %; fondo mixto +106 % frente a +120 %. En el fondo de bonos no entra.
  - DQN cambia retorno por riesgo: en el S&P 500 gana +179 %, con caída máxima del 25 % frente al 34 % de B&H.

5. Análisis crítico y conclusiones

- **DQN y A3C aprenden lo esperado.** Ninguno descubre nada que no capture ya una buena regla con histéresis. El techo lo pone el estado: sin la distancia a la media ni el régimen, el oráculo queda lejos (48 % en reversión, 0 % en regímenes).
- **A3C no es peor que DQN:** en reversión es mejor y más estable entre semillas. Pero es más sensible a sus hiperparámetros (en reversión, variación entre configuraciones de 7,7 puntos, frente a 2,9 de error) y, como DQN, oscila en reversión.
- **El criterio de convergencia sobre la mediana en % engaña en ciclo:** una mediana de +80.000 % varía más de un 10 % por puro ruido. Por eso medimos la convergencia sobre G.
- **Lección de método:** sin el test intermitente, habríamos atribuido a A3C la inestabilidad de nuestra implementación. **Limitaciones:** comisión fija, ajuste con 3 semillas y tiempos medidos en un portátil de 16 núcleos.