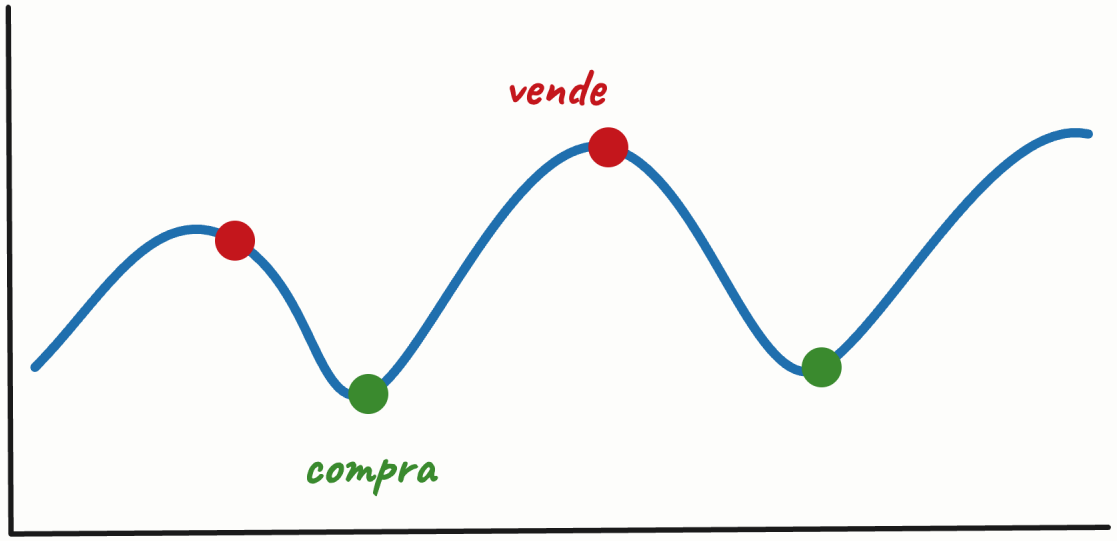


DQN y A3C

¿cuándo estar dentro de un activo?

Taller 2 de Aprendizaje por Refuerzo
Máster MIAX · noviembre de 2026

NATALIA SAN JOSÉ ORTEGA
JOSEP PÉREZ SEGURA
EMILIO SÁNCHEZ MARTÍNEZ

EL PROBLEMA

Un agente decide en cada paso: vender, mantener o comprar, con un 0,1 % de comisión

ESTADO

tendencia de 6 precios y posición

continuo, sin intervalos

→

DQN

aprende el valor de cada acción

buffer de 100.000 · red objetivo

+ Doble DQN y DQN en duelo

A3C

aprende la política, con un crítico

4 trabajadores asíncronos

+ REINFORCE: uno solo, sin crítico

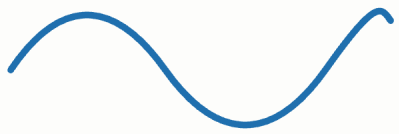
sin el factor γ^t · cerrojo en Adam

→

ACCIÓN

vender · mantener · comprar

recompensa normalizada, sin recortar a ±1



ciclo



browniano



reversión a la media



alternancia de regímenes

LO QUE HICIMOS

Más de 1.000 entrenamientos, organizados en seis bloques

1 DISEÑO

5 agentes, estado continuo

DQN, Doble DQN, DQN en duelo, A3C y REINFORCE, en 4 mercados

2 AJUSTE

693 entrenamientos

a y z, exploración, pérdida y episodios, por etapas y con 3 semillas

3 TEST

200 entrenamientos

10 semillas nuevas por agente y mercado, en las series del taller anterior

4 PRUEBAS

5 pruebas complementarias

concurrencia de A3C, buffer, MSE o MAE, trabajadores y datos reales

5 ESTABILIZAR

72 entrenamientos

calendarios de aprendizaje, entropía y red objetivo, en reversión

6 MÁS SEMILLAS

30 entrenamientos

repetir la elección de hiperparámetros con 5 semillas nuevas

Todo se decide en validación (100 series); el test (otras 100 series) queda fuera del ajuste.

RESULTADOS EN TEST

En reversión ganan A3C y REINFORCE: +27–29 % frente a +21–22 %

Referencias	ciclo	browniano	reversión	regímenes
Buy & hold	+3.425	+0,7	−1,1	−20,4
Momentum	+48.189	−11,8	−28,7	−18,4
Contrarian	−92,9	−14,3	+6,9	−22,6
Q-learning	+64.989	0	+22,0	+1,7
Sarsa	+67.861	0	+22,2	+4,7

Nuestros agentes	ciclo	browniano	reversión	regímenes
DQN	+59.363	0	+22,1	0
Doble DQN	+59.363	0	+21,0	0
DQN en duelo	+60.723	0	+22,2	0
A3C	+63.619	0	+27,5	0
REINFORCE	+59.905	0	+28,6	0

Ciclo: unas 600 veces el capital; superan a momentum, pero no mejoran al tabular

Reversión: los métodos de actor sacan entre 5 y 7 puntos a DQN y al tabular

Browniano y regímenes: no operan; el tabular sacaba +2–5 % en regímenes

Mediana del retorno en test (%), 100 series × 10 semillas · Q-learning y Sarsa: taller anterior, mismas series · el ciclo es sintético, no una expectativa real

LO QUE APRENDIERON

Aprenden la estrategia esperada en los cuatro mercados

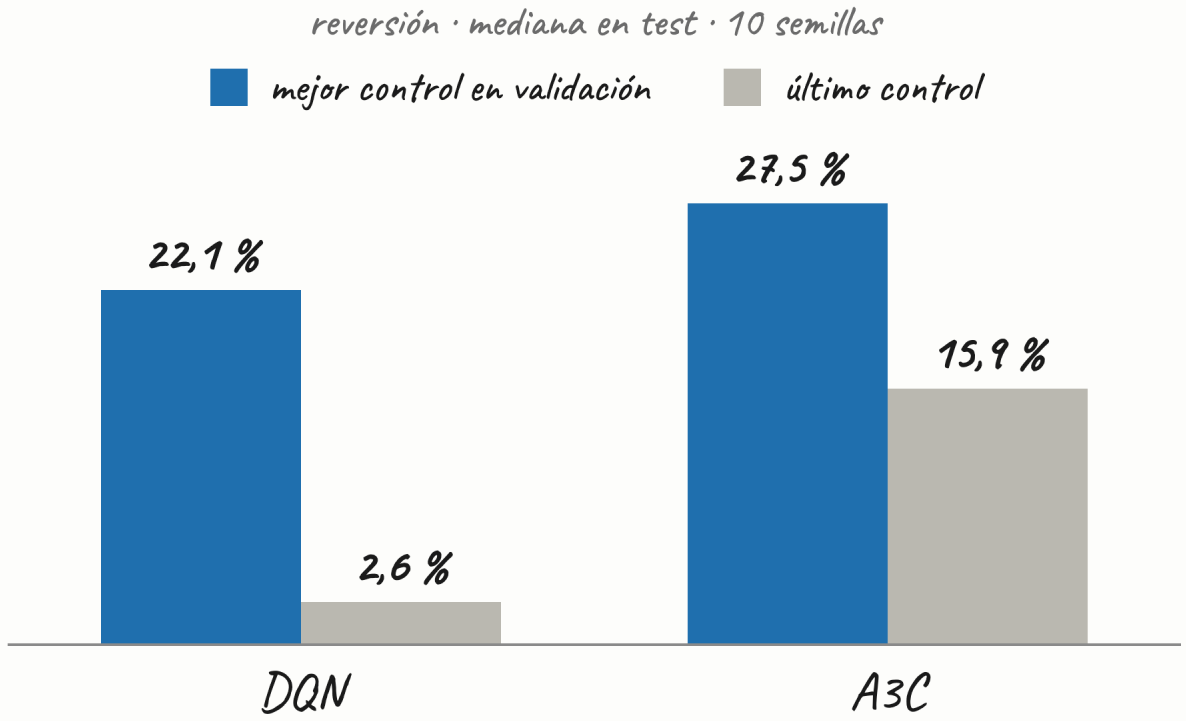
tendencia normalizada, de −3σ a +3σ →

CICLO	vende si < −0,7σ	mantiene	compra si > +0,5σ	momentum con histéresis: ahorra comisiones
REVERSIÓN	compra si < −1,5σ	mantiene hasta el rebote	vende si > +1–1,5σ	contrarian solo en los extremos
BROWNIANO	no opera o compra y mantiene: da igual			no hay señal que aprovechar
REGÍMENES	no entra			la tendencia no distingue el régimen

Techo: en reversión, un oráculo logra $G \approx 0{,}63$ y los agentes 0,25–0,30. Lo que falta está en el estado (la distancia a la media, la volatilidad), no en el algoritmo.

¿CONVERGE?

En ciclo converge en 50 episodios; en reversión oscila



Ciclo: DQN y A3C llegan al criterio en 50 episodios (≈ 7 s y ≈ 2 s)

Reversión: DQN en 375 episodios (≈ 49 s); A3C en 3.200 (≈ 130 s), casi todo el presupuesto

Con 12.800 episodios, A3C sigue oscilando entre G ≈ 0,12 y 0,30

Por eso guardamos el mejor control en validación

PRUEBAS COMPLEMENTARIAS

Arreglamos un fallo de A3C; con datos reales nadie gana a buy & hold

UN FALLO DE CONCURRENCIA EN A3C

Los procesos compartían el estado de Adam sin cerrojo: un solo paso llevaba los pesos de 0,7 a más de 1.000, y con la misma semilla A3C unas veces aprendía y otras dejaba de operar.

Lo destapó un test que fallaba de vez en cuando. Arreglo: un cerrojo solo en ese paso; los gradientes siguen siendo asíncronos.

5,3 % → 25,2 %

peor semilla en reversión

23,6 % → 27,5 %

mediana en reversión

MSE O MAE

ninguna diferencia supera el error de 3 semillas

no cambia la conclusión

BUFFER DE DQN

una pasada por episodio: 24,4 %; minibatch: 22,1 %; 16 pasadas: 10,8 %

repetir la última serie la sobreajusta

TRABAJADORES

1, 2, 4 y 8 trabajadores: 57, 33, 23 y 21 s

mismo resultado; más allá de 4 apenas acelera

DATOS REALES

S&P 500 desde 2019: buy & hold +193 %, A3C +190 %, DQN +179 %

nadie lo supera; DQN cae menos (25 % frente a 34 %)

ESTABILIZAR EL ENTRENAMIENTO

Bajar a estabiliza DQN; en A3C suaviza la curva, pero rinde menos

DQN: APRENDIZAJE DECRECIENTE

reversión · validación · 5 semillas nuevas

	original	a decreciente
G al final	0,133	0,217
oscilación	0,075	0,040
retorno al final	6,3 %	18,1 %
brecha mejor–último	18,4 pp	5,9 pp

Mejora en 5 de 5 semillas

El mejor retorno apenas cambia (24,7 % frente a 24,0 %): gana terminar bien

Falta evaluarlo en un test independiente

A3C: APRENDIZAJE DECRECIENTE

reversión · validación · 3 semillas · 3.200 episodios

a final	G al final	oscilación	retorno
constante	0,238	0,053	16,1 %
al 10 %	0,196	0,008	12,7 %
al 30 %	0,233	0,037	16,6 %

Con 12.800 episodios bajar a sí ayudaba; con 3.200 depende del calendario

Ninguna variante reduce la oscilación sin perder rendimiento: se queda el original

Test reservado: 26,7 % con el mejor control y 16,2 % con el último

¿Y CON MÁS SEMILLAS?

Con 5 semillas nuevas, ninguna alternativa gana con claridad

30 entrenamientos en reversión: 6 configuraciones × 5 semillas nuevas

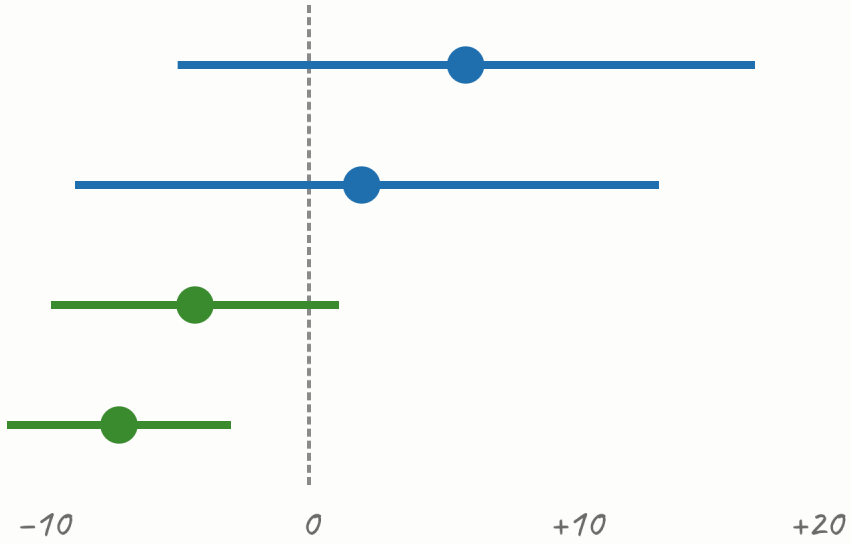
ventaja frente a la configuración elegida, en puntos · intervalo bootstrap orientativo

DQN · α 0,0001, γ 0
21,9 % frente a 16,1 %

DQN · pérdida MAE
18,0 % frente a 16,1 %

A3C · 800 episodios, MAE
26,3 % frente a 30,6 %

A3C · 800 episodios, MSE, 5 pasos
23,4 % frente a 30,6 %



DQN elegido: 28,3 % con 3 semillas → 16,1 % con 5 nuevas

A3C elegido: 30,8 % → 30,6 %, estable

Se mantienen las configuraciones elegidas

Para cambiar exigíamos un intervalo positivo y una mejora de más de 1 punto y del 5 %

CONCLUSIONES

1. Aprenden la estrategia esperada; en reversión, A3C y REINFORCE superan a DQN y al tabular
2. En reversión el entrenamiento oscila: hay que quedarse con el mejor control en validación
3. Un test que fallaba de vez en cuando destapó un fallo de concurrencia en A3C
4. Bajar a estabiliza DQN (5 de 5 semillas); en A3C, suavizar la curva costó rendimiento
5. Con más semillas se mantienen las configuraciones: la ventaja de DQN era incierta

Límites: pocas semillas, validación reutilizada, sin corrección por comparaciones múltiples y comisión fija. La mejora de DQN aún no tiene test.

¡Gracias!