Métodos basados en el gradiente de la política

Manuel Sánchez-Montañés

1. Concepto
2. Formalización
3. Parametrización de la política
4. Teorema del gradiente de políticas
5. Algoritmo REINFORCE

Concepto

Métodos basados en el gradiente de la política: concepto

- Q-learning estima los valores de las acciones y luego con ellos actualiza la política

Métodos basados en el gradiente de la política: concepto

- Q-learning estima los valores de las acciones y luego con ellos actualiza la política
- Los algoritmos basados en la política aprenden directamente la política

Métodos basados en el gradiente de la política: concepto

- Q-learning estima los valores de las acciones y luego con ellos actualiza la política
- Los algoritmos basados en la política aprenden directamente la política
- Normalmente estiman una política estocástica

Métodos basados en el gradiente de la política: concepto

- Q-learning estima los valores de las acciones y luego con ellos actualiza la política
- Los algoritmos basados en la política aprenden directamente la política
- Normalmente estiman una política estocástica
- En MDPs siempre existe una política determinista que maximiza el valor de cada estado

Métodos basados en el gradiente de la política: concepto

Hay varias razones para usar una política estocástica:

Métodos basados en el gradiente de la política: concepto

Hay varias razones para usar una política estocástica:

- Ayuda de manera natural a explorar el espacio: no estamos obligados a tomar solo una acción en cada estado

Métodos basados en el gradiente de la política: concepto

Hay varias razones para usar una política estocástica:

- Ayuda de manera natural a explorar el espacio: no estamos obligados a tomar solo una acción en cada estado
- El coste a optimizar varía suavemente si cambiamos los parámetros de la política: podemos usar métodos basados en gradiente para optimizarla, aunque los refuerzos sean discretos

Formalización

Formalización

- Se parametriza la política: la probabilidad de realizar cada una de las acciones **a** en cada estado **s** es una función que depende de unos parámetros **θ**

$$\pi(a|s,\theta) = P\left(A_t = a|S_t = s,\theta\right)$$

Formalización

- Se parametriza la política: la probabilidad de realizar cada una de las acciones **a** en cada estado **s** es una función que depende de unos parámetros **θ**

$$\pi(a|s,\theta) = P\left(A_t = a|S_t = s,\theta\right)$$

- Se define una métrica de rendimiento $J(\boldsymbol{\theta})$ y se aplica ascenso por gradiente para optimizarla:

$$\theta_{t+1} = \theta_t + \alpha \cdot \widehat{\nabla J(\theta)}$$

Formalización

- Se parametriza la política: la probabilidad de realizar cada una de las acciones **a** en cada estado **s** es una función que depende de unos parámetros **θ**

$$\pi(a|s,\theta) = P\left(A_t = a|S_t = s,\theta\right)$$

- Se define una métrica de rendimiento $J(\boldsymbol{\theta})$ y se aplica ascenso por gradiente para optimizarla:

$$\theta_{t+1} = \theta_t + \alpha \cdot \widehat{\nabla J(\theta)}$$

- α es la tasa de actualización, que multiplica a la estimación del gradiente de *J* (rendimiento)

Parametrización de la política

Parametrización de la política

Una manera habitual de parametrizar π (a|s,$\boldsymbol{\theta}$) es la siguiente:

- Se define una función de preferencia h a cada par estado-acción:

$$h(s, a, \boldsymbol{\theta}) \in \mathcal{R}$$

Parametrización de la política

Una manera habitual de parametrizar π (a|s,$\boldsymbol{\theta}$) es la siguiente:

- Se define una función de preferencia h a cada par estado-acción:

$$h(s, a, \boldsymbol{\theta}) \in \mathcal{R}$$

- Cuanto más probable es la acción, más grande es h

Parametrización de la política

Una manera habitual de parametrizar π (a|s,$\boldsymbol{\theta}$) es la siguiente:

- Se define una función de preferencia h a cada par estado-acción:

$$h(s, a, \boldsymbol{\theta}) \in \mathcal{R}$$

- Cuanto más probable es la acción, más grande es h
- h puede ser de muchas formas:
  - Una función lineal: $h(s, a, \boldsymbol{\theta}) = \boldsymbol{\theta}^T \cdot \mathbf{x}(s, a)$
  - Una red neuronal (los $\boldsymbol{\theta}$ serían los pesos)
  - Etc.

Parametrización de la política

- La política se define entonces como:

$$\pi(a|s,\theta) = \frac{e^{h(s,a,\theta)}}{\sum_{a'} e^{h(s,a',\theta)}}$$

Parametrización de la política

- La política se define entonces como:

$$\pi(a|s,\theta) = \frac{e^{h(s,a,\theta)}}{\sum_{a'} e^{h(s,a',\theta)}}$$

- Esta función softmax garantiza que la suma de las probabilidades de todas las acciones que se pueden hacer desde el estado **s** sea 1

Teorema del gradiente de políticas

Teorema del gradiente de políticas

- Este teorema es fundamental. Permite calcular el gradiente de J de manera sencilla.

Teorema del gradiente de políticas

- Este teorema es fundamental. Permite calcular el gradiente de J de manera sencilla.
- Teorema:

$$\nabla J(\boldsymbol{\theta}) \propto \sum_{s} \mu(s) \sum_{a} q_{\pi}(s, a) \nabla \pi(a|s, \boldsymbol{\theta})$$

Teorema del gradiente de políticas

- Este teorema es fundamental. Permite calcular el gradiente de J de manera sencilla.
- Teorema:

$$\nabla J(\theta) \propto \sum_{s} \mu(s) \sum_{a} q_{\pi}(s, a) \nabla \pi(a|s, \theta)$$

- $\propto$ quiere decir "*proporcional a*"

Teorema del gradiente de políticas

- Este teorema es fundamental. Permite calcular el gradiente de J de manera sencilla.
- Teorema:

$$\nabla J(\theta) \propto \sum_s \mu(s) \sum_a q_\pi(s,a) \nabla \pi(a|s,\theta)$$

- $\propto$ quiere decir "*proporcional a*"
- μ(s) es la proporción de veces (en tanto por 1) que se visita el estado s (se puede estimar con observaciones)

Teorema del gradiente de políticas

- Este teorema es fundamental. Permite calcular el gradiente de J de manera sencilla.
- Teorema:

$$\nabla J(\theta) \propto \sum_s \mu(s) \sum_a q_\pi(s,a) \nabla \pi(a|s,\theta)$$

- $\propto$ quiere decir "*proporcional a*"
- μ(s) es la proporción de veces (en tanto por 1) que se visita el estado s (se puede estimar con observaciones)
- q_π es la función de acción-valor (se puede estimar con observaciones)

Teorema del gradiente de políticas

- Este teorema es fundamental. Permite calcular el gradiente de J de manera sencilla.
- Teorema:

$$\nabla J(\theta) \propto \sum_s \mu(s) \sum_a q_\pi(s,a) \nabla \pi(a|s,\theta)$$

- $\propto$ quiere decir "*proporcional a*"
- μ(s) es la proporción de veces (en tanto por 1) que se visita el estado s (se puede estimar con observaciones)
- q_π es la función de acción-valor (se puede estimar con observaciones)
- $\nabla \pi(a|s,\theta)$ es el gradiente de la política respecto a **θ** (lo sabemos)

Algoritmo REINFORCE

Algoritmo REINFORCE

- Es un algoritmo bastante conocido de gradiente de la política

Algoritmo REINFORCE

- Es un algoritmo bastante conocido de gradiente de la política
- Genera episodios completos basándose en la política actual

Algoritmo REINFORCE

- **Entrada:** función política parametrizada $\pi(a|s,\boldsymbol{\theta})$. Los $\boldsymbol{\theta}$ son los parámetros de la función. $\pi(a|s,\boldsymbol{\theta})$ debe ser derivable respecto a $\boldsymbol{\theta}$.
  Hiperparámetros: α (tamaño de paso). Factor de descuento γ

Algoritmo REINFORCE

- **Entrada:** función política parametrizada $\pi(a|s,\boldsymbol{\theta})$. Los $\boldsymbol{\theta}$ son los parámetros de la función. $\pi(a|s,\boldsymbol{\theta})$ debe ser derivable respecto a $\boldsymbol{\theta}$. **Hiperparámetros:** α (tamaño de paso). Factor de descuento γ
- Inicializar $\boldsymbol{\theta}$ (por ejemplo, a 0)

Algoritmo REINFORCE

- **Entrada:** función política parametrizada $\pi(a|s,\boldsymbol{\theta})$. Los $\boldsymbol{\theta}$ son los parámetros de la función. $\pi(a|s,\boldsymbol{\theta})$ debe ser derivable respecto a $\boldsymbol{\theta}$. **Hiperparámetros:** α (tamaño de paso). Factor de descuento γ
- Inicializar $\boldsymbol{\theta}$ (por ejemplo, a 0)
- Por cada episodio:

Algoritmo REINFORCE

- **Entrada:** función política parametrizada $\pi(a|s,\boldsymbol{\theta})$. Los $\boldsymbol{\theta}$ son los parámetros de la función. $\pi(a|s,\boldsymbol{\theta})$ debe ser derivable respecto a $\boldsymbol{\theta}$. **Hiperparámetros:** α (tamaño de paso). Factor de descuento γ
- Inicializar $\boldsymbol{\theta}$ (por ejemplo, a 0)
- Por cada episodio:
  - Generar episodio $S_0, A_0, R_1, \ldots, S_{T-1}, A_{T-1}, R_T$ siguiendo $\pi(a|s,\boldsymbol{\theta})$

Algoritmo REINFORCE

- **Entrada:** función política parametrizada $\pi(a|s,\boldsymbol{\theta})$. Los $\boldsymbol{\theta}$ son los parámetros de la función. $\pi(a|s,\boldsymbol{\theta})$ debe ser derivable respecto a $\boldsymbol{\theta}$. **Hiperparámetros:** α (tamaño de paso). Factor de descuento γ
- Inicializar $\boldsymbol{\theta}$ (por ejemplo, a 0)
- Por cada episodio:
  - Generar episodio $S_0, A_0, R_1, \ldots, S_{T-1}, A_{T-1}, R_T$ siguiendo $\pi(a|s,\boldsymbol{\theta})$
  - Por cada paso del episodio t=0, 1, …, T-1:

Algoritmo REINFORCE

- **Entrada:** función política parametrizada $\pi(a|s,\boldsymbol{\theta})$. Los $\boldsymbol{\theta}$ son los parámetros de la función. $\pi(a|s,\boldsymbol{\theta})$ debe ser derivable respecto a $\boldsymbol{\theta}$.
  Hiperparámetros: α (tamaño de paso). Factor de descuento γ
- Inicializar $\boldsymbol{\theta}$ (por ejemplo, a 0)
- Por cada episodio:
  - Generar episodio $S_0, A_0, R_1, \ldots, S_{T-1}, A_{T-1}, R_T$ siguiendo $\pi(a|s,\boldsymbol{\theta})$
  - Por cada paso del episodio t=0, 1, …, T-1:
    - Se calcula G_t: $G_t = \sum_{k=t+1}^{T} \gamma^{k-t-1} R_k$ → **Retorno calculado desde el paso t**

Algoritmo REINFORCE

- **Entrada:** función política parametrizada $\pi(a|s,\boldsymbol{\theta})$. Los $\boldsymbol{\theta}$ son los parámetros de la función. $\pi(a|s,\boldsymbol{\theta})$ debe ser derivable respecto a $\boldsymbol{\theta}$.
  Hiperparámetros: α (tamaño de paso). Factor de descuento γ
- Inicializar $\boldsymbol{\theta}$ (por ejemplo, a 0)
- Por cada episodio:
  - Generar episodio $S_0, A_0, R_1, \ldots, S_{T-1}, A_{T-1}, R_T$ siguiendo $\pi(a|s,\boldsymbol{\theta})$
  - Por cada paso del episodio t=0, 1, …, T-1:
    - Se calcula G_t: $G_t = \sum_{k=t+1}^{T} \gamma^{k-t-1} R_k$ → **Retorno calculado desde el paso t**
    - Se actualiza $\boldsymbol{\theta}$: $\Delta\theta = \alpha \cdot \gamma^t \cdot G_t \cdot \nabla ln\, \pi\,(A_t|S_t, \theta)$

Algoritmo REINFORCE

- **Entrada:** función política parametrizada $\pi(a|s,\boldsymbol{\theta})$. Los $\boldsymbol{\theta}$ son los parámetros de la función. $\pi(a|s,\boldsymbol{\theta})$ debe ser derivable respecto a $\boldsymbol{\theta}$.
  Hiperparámetros: α (tamaño de paso). Factor de descuento γ
- Inicializar $\boldsymbol{\theta}$ (por ejemplo, a 0)
- Por cada episodio:
  - Generar episodio $S_0, A_0, R_1, \ldots, S_{T-1}, A_{T-1}, R_T$ siguiendo $\pi(a|s,\boldsymbol{\theta})$
  - Por cada paso del episodio t=0, 1, …, T-1:
    - Se calcula G_t: $G_t = \sum_{k=t+1}^{T} \gamma^{k-t-1} R_k$ → **Retorno calculado desde el paso t**
    - Se actualiza $\boldsymbol{\theta}$: $\Delta\theta = \alpha \cdot \gamma^t \cdot G_t \cdot \nabla ln\, \pi\,(A_t|S_t, \theta)$

Algoritmo REINFORCE

Nota:

$$\nabla ln\, \pi\,(A_t|S_t,\theta) = \frac{1}{\pi\,(A_t|S_t,\theta)} \cdot \nabla \pi\,(A_t|S_t,\theta)$$