Métodos Actor-Crítico

Manuel Sánchez-Montañés

Algoritmo REINFORCE (policy gradient)

- **Entrada:** función política parametrizada $\pi(a|s,\boldsymbol{\theta})$. Los **θ** son los parámetros de la función. $\pi(a|s,\boldsymbol{\theta})$ debe ser derivable respecto a. **Hiperparámetros:** α (tamaño de paso). Factor de descuento γ
- Inicializar **θ** (por ejemplo, a 0)
- Por cada episodio:
  - Generar episodio $S_0, A_0, R_1, \ldots, S_{T-1}, A_{T-1}, R_T$ siguiendo $\pi(a|s,\boldsymbol{\theta})$
  - Por cada paso del episodio t=0, 1, …, T-1:
    - Se calcula G_t: $G_t = \sum_{k=t+1}^{T} \gamma^{k-t-1} R_k$ → **Retorno calculado desde el paso t**
    - Se actualiza **θ**: $\Delta\theta = \alpha \cdot \gamma^t \cdot G_t \cdot \nabla ln\, \pi\,(A_t|S_t, \theta)$

Algoritmo REINFORCE (policy gradient)

- **Entrada:** función política parametrizada $\pi(a|s,\boldsymbol{\theta})$. Los **θ** son los parámetros de la función. $\pi(a|s,\boldsymbol{\theta})$ debe ser derivable respecto a. **Hiperparámetros:** α (tamaño de paso). Factor de descuento γ
- Inicializar **θ** (por ejemplo, a 0)
- Por cada episodio:
  - Generar episodio $S_0, A_0, R_1, \ldots, S_{T-1}, A_{T-1}, R_T$ siguiendo $\pi(a|s,\boldsymbol{\theta})$
  - Por cada paso del episodio t=0, 1, …, T-1:
    - Se calcula G_t: $G_t = \sum_{k=t+1}^{T} \gamma^{k-t-1} R_k$ → **Retorno calculado desde el paso t**
    - Se actualiza **θ**: $\Delta\theta = \alpha \cdot \gamma^t \cdot G_t \cdot \nabla ln\, \pi\,(A_t|S_t, \theta)$

Métodos Actor-Crítico

- **Idea:** utilizar dos modelos, uno para la política π (“actor”) y otro para el valor G (“crítico”)

Métodos Actor-Crítico

- **Idea:** utilizar dos modelos, uno para la política π (“actor”) y otro para el valor G (“crítico”)
- Cada uno de esos modelos puede ser de diferente tipo (por ejemplo una red neuronal, y un modelo lineal respectivamente), que tienen sus propios parámetros

Algoritmo Actor-crítico

- **Entrada:** función política parametrizada derivable $\pi(a|s,\boldsymbol{\theta})$ y función de valoración derivable v(s,**w**). **Hiperparámetros:** α_{θ}, $\alpha_{\mathbf{w}}$ (tamaño de los pasos). Factor de descuento γ

Algoritmo Actor-crítico

- Inicializar parámetros $\boldsymbol{\theta}$ y $\mathbf{w}$ (por ejemplo, a 0)

Algoritmo Actor-crítico

- Inicializar parámetros **θ** y **w** (por ejemplo, a 0)
- **Por cada episodio:**

Algoritmo Actor-crítico

- Inicializar parámetros **θ** y **w** (por ejemplo, a 0)
- **Por cada episodio:**
  - Inicializar S (primer estado del episodio). Inicializar $I \leftarrow 1$

Algoritmo Actor-crítico

- Inicializar parámetros **θ** y **w** (por ejemplo, a 0)
- **Por cada episodio:**
  - Inicializar S (primer estado del episodio). Inicializar $I \leftarrow 1$
  - Episodio: mientras que S no sea terminal:

Algoritmo Actor-crítico

- Inicializar parámetros **θ** y **w** (por ejemplo, a 0)
- **Por cada episodio:**
  - Inicializar S (primer estado del episodio). Inicializar $I \leftarrow 1$
  - Episodio: mientras que S no sea terminal:
    - Generar A de acuerdo a π, realizar A, y observar S', R

Algoritmo Actor-crítico

- Inicializar parámetros **θ** y **w** (por ejemplo, a 0)
- **Por cada episodio:**
  - Inicializar S (primer estado del episodio). Inicializar $I \leftarrow 1$
  - Episodio: mientras que S no sea terminal:
    - Generar A de acuerdo a π, realizar A, y observar S', R
    - Calcular error en v de acuerdo a Bellman:

$$\delta = R + \gamma \cdot v(S', \mathbf{w}) - v(S, \mathbf{w})$$

Nota: v es 0 si S' es terminal

Algoritmo Actor-crítico

- Inicializar parámetros **θ** y **w** (por ejemplo, a 0)
- **Por cada episodio:**
  - Inicializar S (primer estado del episodio). Inicializar $I \leftarrow 1$
  - Episodio: mientras que S no sea terminal:
    - Generar A de acuerdo a π, realizar A, y observar S', R
    - Calcular error en v de acuerdo a Bellman:

      $\delta = R + \gamma \cdot v(S', \mathbf{w}) - v(S, \mathbf{w})$ Nota: v es 0 si S' es terminal
    - Actualizar **w**: $\Delta \mathbf{w} = \alpha_{\mathbf{w}} \delta \nabla v(S, \mathbf{w})$

Algoritmo Actor-crítico

- Inicializar parámetros **θ** y **w** (por ejemplo, a 0)
- **Por cada episodio:**
  - Inicializar S (primer estado del episodio). Inicializar $I \leftarrow 1$
  - Episodio: mientras que S no sea terminal:
    - Generar A de acuerdo a π, realizar A, y observar S', R
    - Calcular error en v de acuerdo a Bellman:

      $\delta = R + \gamma \cdot v(S', \mathbf{w}) - v(S, \mathbf{w})$ Nota: v es 0 si S' es terminal
    - Actualizar **w**: $\Delta \mathbf{w} = \alpha_{\mathbf{w}} \delta \nabla v(S, \mathbf{w})$
    - Actualizar **θ**: $\Delta \theta = \alpha_{\theta} I \, \delta \nabla \ln \pi(A|S, \theta)$

Algoritmo Actor-crítico

- Inicializar parámetros **θ** y **w** (por ejemplo, a 0)
- **Por cada episodio:**
  - Inicializar S (primer estado del episodio). Inicializar $I \leftarrow 1$
  - Episodio: mientras que S no sea terminal:
    - Generar A de acuerdo a π, realizar A, y observar S', R
    - Calcular error en v de acuerdo a Bellman:

      $\delta = R + \gamma \cdot v(S', \mathbf{w}) - v(S, \mathbf{w})$ Nota: v es 0 si S' es terminal
    - Actualizar **w**: $\Delta \mathbf{w} = \alpha_{\mathbf{w}} \delta \nabla v(S, \mathbf{w})$
    - Actualizar **θ**: $\Delta \theta = \alpha_{\theta} I \, \delta \nabla \ln \pi(A|S, \theta)$
    - Actualizar $I \leftarrow \gamma I$, $S \leftarrow S'$

Algoritmo Actor-crítico

- Este esquema tiene muchas variantes, por ejemplo A2C y A3C
  - A2C: “Advantage Actor-Critic”
  - A3C: “Asynchronous Advantage Actor-Critic”